

Student 1 报告：环境设计与专家数据生成

1. 引言

作为 IRL 项目团队的学生 1，我的职责涵盖所有后续逆向强化学习算法所依赖的基础组件：GridWorld 环境设计、状态转移动力学建模、状态特征表示构建，以及高质量的专家演示数据和偏好数据生成。

1.1 职责概述

- 环境设计**：实现带障碍物导航的随机性 10×10 GridWorld
- 转移动力学**：预计算状态转移概率张量 $P[s, a, s']$
- 特征工程**：径向基函数（RBF）状态特征用于奖励表示
- 数据生成**：专家轨迹收集（含可控噪声注入）
- 偏好合成**：Bradley-Terry 偏好对生成（含类人工标注噪声）

2. 环境设计

2.1 GridWorld 配置

环境是一个 10×10 的基于网格的导航任务，具体规格如下：

参数	值	说明
网格大小	10×10	共 100 个状态
目标位置	(9, 9)	右下角
障碍物数量	22	战略性布置的障碍
随机性 (ϵ)	0.1	10% 动作噪声
折扣因子 (γ)	0.9	未来奖励折扣
最大回合步数	200	回合长度限制

图引用：见图 `s1_env_layout.png` 了解完整的环境布局，包括障碍物位置、目标位置和起点位置。

2.2 障碍物布置策略

22 个障碍物在网格中战略性分布，创造非平凡的导航挑战：

- 走廊形成**：(2,0)-(2,1) 和 (5,2)-(5,3) 的障碍物形成狭窄通道
- 类迷宫结构**：第 3-5 行的障碍物簇迫使智能体寻找间接路径
- 开放区域**：第 6-7 行相对开放，用于高效导航
- 目标区域保护**：(8,4)-(8,6)、(9,1)、(9,6) 等障碍物围绕目标形成保护区域
- 顶部障碍**：(0,5)、(1,5) 阻挡了从起点直接向右的路径
- 底部障碍**：(7,1)、(7,7)、(8,1) 等增加底部区域复杂度

完整的 22 个障碍物位置：

(0,5), (1,5), (2,0), (2,1), (3,3), (3,5), (3,6), (3,8), (4,3), (4,8), (5,2), (5,3), (5,8), (5,9), (7,1), (7,7), (8,1), (8,4), (8,5), (8,6), (9,1),

这种布局确保最优策略必须展现真正的路径规划能力，而非简单的贪婪向目标移动。

2.3 随机转移模型

转移动力学建模为：

$$P(s'|s, a) = (1 - \epsilon) \cdot \mathbb{I}[s' = f(s, a)] + \frac{\epsilon}{|A| - 1} \sum_{a' \neq a} \mathbb{I}[s' = f(s, a')]$$

其中：

- $\epsilon = 0.1$ 是随机性参数
- $f(s, a)$ 是确定性转移函数
- $|A| = 4$ 是动作数量（上、下、左、右）

实现细节：

- 完整的转移张量 $P \in \mathbb{R}^{100 \times 4 \times 100}$ 在初始化时预计算
- 边界条件：导致网格外的动作使智能体留在原地（反弹）
- 障碍物碰撞：进入障碍物状态的转移被重定向到当前状态
- 数值稳定性：所有概率分布在构建后进行归一化

图引用：见图 `s1_transition_analysis.png` 了解不同随机性水平下的转移概率分布可视化。

2.4 终止条件

回合在以下情况终止：

- 智能体到达目标状态 (9, 9) — **成功**
- 智能体进入障碍物状态 — **失败**
- 达到最大回合长度（200 步） — **超时**

2.5 真实奖励函数

真实奖励向量定义为：

$$R_{gt}(s) = \begin{cases} +1.0 & \text{如果 } s = \text{目标} \\ -1.0 & \text{如果 } s = \text{障碍物} \\ 0.0 & \text{其他情况} \end{cases}$$

这种稀疏奖励结构用于生成专家演示，并作为评估 IRL 奖励恢复质量的基准。

3. 特征表示

3.1 RBF 特征设计

我们采用维度 $d = 3$ 的径向基函数（RBF）特征来表示状态空间。选择 RBF 特征是因为它们能自然地表示稀疏奖励结构，并在状态之间提供平滑的泛化。

特征 1：目标接近度（高斯）

$$\phi_1(s) = \exp\left(-\frac{d(s, \text{goal})^2}{2\sigma_1^2}\right), \quad \sigma_1 = 3.0$$

该特征编码状态距离目标的远近，在目标附近值接近 1.0，远离时衰减到 0.0。

特征 2：障碍物距离（反向）

$$\phi_2(s) = 1.0 - \exp\left(-\frac{d(s, \text{最近障碍物})^2}{2\sigma_2^2}\right), \quad \sigma_2 = 2.0$$

该特征捕获障碍物规避行为，远离障碍物时值接近 1.0，靠近障碍物时接近 0.0。

特征 3：常数偏置

$$\phi_3(s) = 1.0 \quad \forall s$$

偏置特征允许奖励函数表示均匀偏移，这对于正确的价值函数校准至关重要。

图引用：见图 `s1_rbf_features.png` 了解三个 RBF 特征维度在网格上的热力图。

3.2 特征矩阵性质

特征矩阵 $\Phi \in \mathbb{R}^{100 \times 3}$ 具有以下性质：

- 秩**：满列秩（秩 = 3），确保权重恢复的唯一性
- 归一化**：所有特征有界于 [0, 1]，防止尺度模糊
- 平滑性**：高斯/RBF 核提供平滑的空间泛化

3.3 为什么选择 RBF 而非 One-Hot?

性质	One-Hot (100 维)	RBF (3 维)
维度	100（维度灾难）	3（紧凑）
泛化	状态间无泛化	平滑空间泛化
奖励模糊性	严重（许多奖励向量解释相同行为）	减少（结构性约束）
计算成本	高（大型 LP/SOCP 问题）	低（小型优化问题）
可解释性	每个状态有独立奖励	奖励具有空间结构

4. 专家轨迹生成

4.1 最优策略计算

专家策略 π_E 通过对真实奖励运行值迭代获得：

$$V(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) [R_{gt}(s') + \gamma V(s')]$$

算法在 $\max_s |V_{new}(s) - V_{old}(s)| < 10^{-9}$ 时收敛，通常在 50-100 次迭代内完成。

4.2 干净专家轨迹

生成协议：

- 回合数**：500
- 起始状态**：从有效（非障碍物、非目标）状态中随机采样
- 动作选择**： $\pi_E(s) = \arg \max_a Q(s, a)$ （确定性专家）
- 回合多样性**：每个回合使用不同的随机种子（seed + episode_index）

统计摘要：

指标	值
轨迹数量	500
平均轨迹长度	~18 步
平均折扣回报	0.328 ± 0.216
成功率	~95%+

图引用：见图 s1_trajectories_comparison.png（左面板）了解干净轨迹的状态访问热力图。

4.3 噪声专家轨迹

为了模拟专家演示中现实的不完美性，我们注入动作噪声：

动作翻转噪声模型：

$$\pi_{noisy}(s) = \begin{cases} \pi_E(s) & \text{概率 } 1 - \eta \\ \text{Random}(A) & \text{概率 } \eta \end{cases}$$

其中 $\eta = 0.15$ （15% 翻转概率）。

选择 15% 噪声的理由：

- 模拟次优专家（例如人类学习者）
- 为消融实验创造足够的变异
- 保持轨迹质量（大多数轨迹仍能到达目标）

数据集摘要：

数据集	回合数	噪声水平	用途
干净	500	0%	主要 IRL 训练数据
噪声	500	15%	鲁棒性评估、偏好数据

图引用：见图 `s1_trajectories_comparison.png`（右面板）了解与噪声轨迹的对比。

5. 偏好数据生成

5.1 Bradley-Terry 偏好模型

偏好对使用 Bradley-Terry 模型生成，该模型假设：

$$P(\tau_i \succ \tau_j) = \sigma(R(\tau_i) - R(\tau_j)) = \frac{1}{1 + \exp(-(R(\tau_i) - R(\tau_j)))}$$

其中 $R(\tau) = \sum_{t=0}^T \gamma^t r(s_t)$ 是轨迹 τ 的折扣累积回报。

5.2 生成协议

数据混合：偏好对从 1000 条轨迹的混合池（500 干净 + 500 噪声）中采样。这确保了轨迹质量的多样性。

质量过滤：为确保信息丰富的偏好对，我们过滤掉 $|R(\tau_i) - R(\tau_j)| < 0.01$ 的配对。这防止了近相同的轨迹创建模糊的标签。

概率放大：Bradley-Terry 概率被放大 5 倍：

$$P(\tau_i \succ \tau_j) = \sigma(5 \cdot (R(\tau_i) - R(\tau_j)))$$

这创造更尖锐的偏好信号，使学习任务更易处理。

噪声注入：5% 偏好标签噪声模拟人工标注错误：

$$\tilde{y} = \begin{cases} y & \text{概率 } 0.95 \\ 1 - y & \text{概率 } 0.05 \end{cases}$$

5.3 偏好数据集统计

指标	值
总偏好对数	300
标签噪声率	5%
正例比例（ τ_i 被偏好）	~52%
平均回报差异	0.3-0.5
轨迹池大小	1000（500 干净 + 500 噪声）

图引用：见图 `s1_preference_data.png` 了解偏好数据分布的完整分析，包括回报直方图、回报差异分布和标签平衡。

5.4 数据质量保证

多项措施确保高质量的偏好数据：

- 1. **基于回报的排序：**轨迹通过其真实折扣回报进行评估
- 2. **多样化采样：**配对采样覆盖一系列回报差异
- 3. **回退机制：**如果质量过滤产生不足的对，使用随机采样补充
- 4. **标签验证：**检查正例比例；如果太接近 50%，发出警告

6. 实现细节

6.1 软件栈

组件	库	版本
环境	Gymnasium	≥0.28.0
数值计算	NumPy	≥1.21.0
优化 (LP)	SciPy (linprog)	≥1.7.0
优化 (SOCP)	CVXPY + SCS	≥1.3.0
可视化	Matplotlib + Seaborn	≥3.5.0
进度跟踪	tqdm	≥4.62.0

6.2 可复现性

所有随机操作都设置种子以确保可复现性：

- 专家轨迹生成： `seed=42` （基础），按回合索引变化
- 偏好生成： `seed=42`
- 噪声注入：消融研究中每个噪声水平使用独立种子

6.3 数据持久化

完整数据集序列化为 `data/expert_dataset.pkl`，包含：

- `clean_trajectories`：500 条干净轨迹列表
- `noisy_trajectories`：500 条噪声轨迹列表
- `preference_pairs`：300 个 (i, j) 索引对
- `preference_labels`：300 个二元标签（1 = i 被偏好）
- `trajectory_returns`：1000 个轨迹回报数组
- `env_config`：环境配置参数字典

7. 挑战与解决方案

7.1 挑战：起始状态多样性

问题：使用单一固定起始状态产生的轨迹数据有偏差，不能覆盖完整状态空间。

解决方案：每个回合采样随机有效起始状态，种子变化确保不同的随机序列。这产生了探索通往目标的不同路径的轨迹。

7.2 挑战：转移矩阵构建

问题：完整的 $100 \times 4 \times 100$ 转移张量需要正确处理边界条件和障碍物碰撞。

解决方案：预计算张量，显式处理边界条件（反弹）和障碍物碰撞（重定向到当前状态）。数值归一化确保有效的概率分布。

7.3 挑战：偏好数据区分度

问题：采样随机轨迹时，许多对具有非常相似的回报，提供弱的学习信号。

解决方案：实现基于回报差异阈值的质量过滤。如果过滤产生太少的对，使用随机采样作为回退。

8. 结论

环境和数据生成管道为 IRL 项目提供了坚实的基础。关键成就包括：

- 1. **精心设计的环境：**10×10 网格含 22 个障碍物，创造需要真正路径规划的非平凡导航
- 2. **RBF 特征：**3 维特征有效捕获空间奖励结构
- 3. **高质量专家数据：**500 条干净 + 500 条噪声轨迹，具有可控噪声水平
- 4. **信息丰富的偏好数据：**300 对 Bradley-Terry 偏好对，具有质量过滤和现实标注噪声
- 5. **可复现管道：**种子随机生成和持久化数据存储使算法间公平比较成为可能

生成的数据直接使学生 2（LP/MM-IRL）、学生 3（MaxEnt-IRL/Preference-BT）和学生 4（策略训练与对比）能够使用可靠的真实基准进行有意义的实验。

本报告引用的图表

图表编号	说明	文件路径
S1-1	环境布局（10×10 网格含 22 个障碍物）	figures/s1_env_layout.png
S1-2	干净与噪声轨迹热力图对比	figures/s1_trajectories_comparison.png
S1-3	偏好数据分布分析	figures/s1_preference_data.png
S1-4	RBF 特征图（3 维）	figures/s1_rbf_features.png
S1-5	状态转移动力学分析（4 宫格）	figures/s1_transition_analysis.png