

# Student 2 报告：线性规划 IRL 与最大边距 IRL

## 1. 引言

作为 IRL 项目团队的学生 2，我的职责聚焦于两种经典的逆向强化学习算法：**线性规划 IRL (LP-IRL)** 和 **最大边距 IRL (MM-IRL)**。这两种方法都属于特征匹配 IRL 方法族，其核心思想是恢复奖励权重，使得专家的特征期望与次优替代方案相匹配或被分离。

### 1.1 职责概述

- **LP-IRL 实现**：带退化预防的线性规划公式
- **MM-IRL 实现**：带最大边距优化的二阶锥规划 (SOCP)
- **次优策略生成**：构造对比性特征期望
- **约束分析**：可行域表征与几何解释
- **奖励恢复**：评估恢复奖励场与真实奖励的对比

## 2. 理论基础

### 2.1 特征匹配原理

LP-IRL 和 MM-IRL 都建立在 Ng & Russell (2000) 的核心洞察之上：如果专家策略  $\pi_E$  在某个奖励函数  $R(s) = \phi(s)^\top w$  下是最优的，那么专家的特征期望  $\mu_E$  必须满足：

$$w^\top (\mu_E - \mu_\pi) \geq 0 \quad \forall \pi$$

其中特征期望定义为：

$$\mu_\pi = \mathbb{E} \left[ \sum_{t=0}^{\infty} \gamma^t \phi(s_t) \mid \pi \right]$$

在我们的实现中，我们使用**折扣归一化**的特征期望：

$$\mu_{\pi} = (1 - \gamma) \cdot \mathbb{E} \left[ \sum_{t=0}^T \gamma^t \phi(s_t) \right]$$

$(1 - \gamma)$  因子确保  $\mu$  表示一个适当的折扣状态分布，使得不同长度策略之间的比较有意义。

## 2.2 奖励模糊性

IRL 中的一个根本性挑战是奖励恢复问题是**不适定的**：无限多的奖励函数可以解释相同的专家行为。例如：

- $R(s) = 0$ （所有状态）使任何策略都是最优的
- $R(s) = c$ （常数）使任何策略同等最优
- 缩放版本  $R'(s) = \alpha R(s)$  产生相同的策略

LP-IRL 和 MM-IRL 通过不同的正则化策略来解决这种模糊性。

## 3. 次优策略构造

### 3.1 次优策略的目的

两种算法都需要来自次优策略的对比性特征期望  $\mu_{sub}$  来创建有意义的约束。如果没有次优对比，平凡解  $w = 0$  将满足所有约束。

### 3.2 三个次优策略

我们生成了三个刻意次优的策略用于约束构造，每个策略运行 200 条轨迹以计算特征期望：

#### 策略 1：纯向上（动作 0）

- 无论状态如何总是向上移动
- 特征期望： $\mu_{up}$  — 严重偏向上方行
- 直觉：无法到达 (9,9) 的目标，访问错误的状态

#### 策略 2：纯向左（动作 2）

- 无论状态如何总是向左移动
- 特征期望： $\mu_{left}$  — 偏向左侧列
- 直觉：远离目标移动，在障碍物处终止

### 策略 3：随机策略

- 均匀随机动作选择
- 特征期望： $\mu_{random}$  — 扩散的状态覆盖
- 直觉：没有连贯的目标导向行为

**图引用：**见图 `s2_suboptimal_trajectories.png` 了解三个次优策略的状态访问频率热力图对比。每个子图使用不同色系（Blues/Oranges/Purples），颜色越深表示访问越频繁，黑色方块标注障碍物位置，红色虚线框标注目标 (9,9)。可以清晰看到：

- 纯向上策略集中在网格上方区域
- 纯向左策略集中在网格左侧
- 随机策略分散在整个网格

## 3.3 特征期望对比

**图引用：**见图 `s2_feature_expectations.png` 了解专家与次优策略在三个 RBF 特征维度上的柱状图对比。

从图中可以直观看到：

- 专家的特征期望  $\mu_E$  在目标接近度（Feature 1）上显著高于所有次优策略
- 在障碍物距离（Feature 2）上，专家也优于纯向左和纯向上策略
- 偏置（Feature 3）差异反映了轨迹长度的不同

这些差异为 IRL 优化创建了非平凡的约束条件。

## 4. 线性规划 IRL

### 4.1 公式

LP-IRL 求解以下优化问题：

$$\begin{aligned} \min_w \quad & - \sum_{i=1}^d w_i \cdot \epsilon \\ \text{s.t.} \quad & w^\top (\mu_E - \mu_{\pi_i}) \geq -\delta \quad \forall i = 1, \dots, K \end{aligned}$$

$$\sum_{i=1}^d w_i = 1$$

$$0 \leq w_i \leq 1 \quad \forall i$$

其中：

- $d = 3$  是特征维度（RBF 特征）
- $K = 3$  是次优策略数量
- $\delta = 5 \times 10^{-4}$  是数值精度的小容差
- $\epsilon = 0.01$  是退化预防目标的权重

## 4.2 退化预防

带有目标  $c = 0$ （纯可行性）的天真公式可能产生退化解。我们使用小的负权重和目标  $c = -0.01 \cdot \mathbf{1}$  来鼓励**非退化解**，使其在特征间分配权重，而非集中在单一特征上。

## 4.3 约束解释与可行域

每个约束  $w^\top (\mu_E - \mu_{\pi_i}) \geq -\delta$  确保恢复的奖励分配给专家特征模式比次优策略模式更高（或相等）的期望值。几何上，这定义了权重空间中的一个**半空间**，可行区域是所有半空间的交集。

**图引用：**见图 `s2_lp_constraints.png` 了解  $w_1$ - $w_2$  平面上可行区域的可视化。图中：

- **绿色区域：**满足所有约束的可行解
- **红色区域：**违反约束的不可行解
- **红色星号：**LP-IRL 找到的最优解

由于  $\sum w_i = 1$  且  $w_i \geq 0$ ，解空间被限制在一个单纯形内。可行区域的大小反映了专家行为与次优行为的区分度。

## 4.4 LP-IRL 实验结果

**策略评估**（固定起点 (0,0)，100 次试验）：

| 指标   | 值      |
|------|--------|
| 成功率  | 100.0% |
| 平均步数 | 20.8   |

| 指标            | 值     |
|---------------|-------|
| Pearson 相关系数  | 0.502 |
| Spearman 相关系数 | 中等    |
| 目标状态排名        | 1/100 |

LP-IRL 恢复的奖励场中，目标 (9,9) 被正确识别为最高奖励状态（排名 1/100），证明算法成功捕获了专家的目标导向意图。

## 5. 最大边距 IRL

### 5.1 公式

MM-IRL 最大化专家与所有次优策略之间的最小边距：

$$\begin{aligned} &\max_{w,m} \quad m \\ \text{s.t.} \quad &w^\top (\mu_E - \mu_{\pi_i}) \geq m \quad \forall i = 1, \dots, K \end{aligned}$$

$$\sum_{i=1}^d w_i = 1$$

$$w \geq 0$$

$$\|w\|_2 \leq 1$$

边距  $m \geq 0$  是额外的优化变量。最大化  $m$  将解决方案推离约束边界，提供对特征期望中噪声的**鲁棒性**。

### 5.2 为什么选择最大边距？

与 LP 公式相比，最大边距方法具有几个优势：

- 1. **鲁棒性**：解决方案尽可能远离决策边界，使其对  $\mu_E$  中的估计误差不太敏感
- 2. **唯一性**：边距最大化通常产生唯一解，而 LP 可能有多个最优解
- 3. **泛化**：大边距解往往能更好地泛化到未见状态

L2 范数约束  $\|w\|_2 \leq 1$  防止平凡解  $w \rightarrow \infty, m \rightarrow \infty$  并确保问题有良好边界。

## 5.3 优化求解器

MM-IRL 被公式化为**二阶锥规划 (SOCP)**，我们使用 CVXPY 搭配 SCS 求解器求解：

```
w = cp.Variable(n_features)
margin = cp.Variable(nonneg=True)
constraints = [w @ (mu_E - mu_sub) >= margin for mu_sub in mu_subs]
constraints.append(cp.sum(w) == 1.0)
constraints.append(w >= 0)
constraints.append(cp.norm(w, 2) <= 1.0)
prob = cp.Problem(cp.Maximize(margin), constraints)
```

## 5.4 MM-IRL 实验结果

**达到的边距**： $m^*$  为正值（表示有效分离）

**策略评估**（固定起点 (0,0)，100 次试验）：

| 指标           | 值      |
|--------------|--------|
| 成功率          | 100.0% |
| 平均步数         | 20.8   |
| Pearson 相关系数 | 0.074  |
| 目标状态排名       | 1/100  |

**图引用**：见图 s2\_mm\_margin.png 了解：

- 左图：三个次优策略各自的边距贡献（柱状图），红色虚线标注最小边距
- 右图：MM-IRL 恢复的三个特征权重值

边距为正值表明专家与次优策略之间有良好的分离，证实了次优策略设计的有效性。

# 6. 奖励场对比分析

## 6.1 奖励场热力图

图引用：见图 s2\_reward\_fields.png 了解三种奖励场的并排对比：

| 位置 | 内容                 | 色系      |
|----|--------------------|---------|
| 左图 | Ground Truth（真实奖励） | RdYlGn  |
| 中图 | LP-IRL 恢复的奖励场      | viridis |
| 右图 | MM-IRL 恢复的奖励场      | viridis |

**Ground Truth**：稀疏奖励结构，目标 (9,9) 处为 +1，22 个障碍物处为 -1，其余为 0。

**LP-IRL**：通过特征匹配恢复的奖励场。可以看到奖励从目标向外逐渐衰减，反映了 RBF 特征的平滑泛化。

**MM-IRL**：通过最大边距优化的奖励场。由于边距最大化的性质，奖励分布更加均匀平滑。

每个子图都标注了奖励范围 [min, max]，障碍物用黑色方块+X 标注，目标用红色虚线框+G 标注。

## 6.2 奖励场差异分析

图引用：见图 s2\_reward\_differences.png 了解三种差异分析的并排对比：

| 位置 | 内容                                           | 色系     |
|----|----------------------------------------------|--------|
| 左图 | LP-IRL vs Ground Truth ( $R_{lp} - R_{gt}$ ) | RdBu_r |
| 中图 | MM-IRL vs Ground Truth ( $R_{mm} - R_{gt}$ ) | RdBu_r |
| 右图 | LP-IRL vs MM-IRL ( $R_{lp} - R_{mm}$ )       | RdBu_r |

**LP vs GT**：LP 恢复奖励与真实奖励的差异。蓝色表示负差异（LP 奖励低于真实），红色表示正差异。

**MM vs GT**：MM 恢复奖励与真实奖励的差异。可以看到 MM-IRL 由于边距最大化，差异模式与 LP 不同。

**LP - MM**：两种算法之间的直接差异，揭示了它们在奖励分配上的根本区别。

6.3 Pearson 相关性分析

| 方法     | Pearson | 成功率    | 说明      |
|--------|---------|--------|---------|
| LP-IRL | 0.502   | 100.0% | 中等线性相关性 |
| MM-IRL | 0.074   | 100.0% | 低线性相关性  |

**关键发现：** 尽管 MM-IRL 的 Pearson 相关系数远低于 LP-IRL (0.074 vs 0.502)，但两者的策略成功率均为 100%。这直接验证了**奖励模糊性**现象：不同的奖励函数可以产生相同的最优策略。

6.4 LP 与 MM 的定性对比

| 方面      | LP-IRL        | MM-IRL         |
|---------|---------------|----------------|
| 奖励分布    | 更集中于约束边界      | 更均匀平滑          |
| 目标识别    | 正确 (排名 1/100) | 正确 (排名 1/100)  |
| 奖励范围    | 较小            | 较大 (受 L2 约束影响) |
| 与 GT 差异 | 中等            | 较大             |

7. 计算复杂度

| 方面   | LP-IRL            | MM-IRL                |
|------|-------------------|-----------------------|
| 问题类型 | 线性规划              | SOCP                  |
| 变量数  | $d + 1 = 4$       | $d + 2 = 5$           |
| 约束数  | $K + 2d + 1 = 10$ | $K + d + 2$ (锥) $= 8$ |
| 求解器  | SciPy HiGHS       | CVXPY SCS             |
| 运行时间 | < 0.01s           | < 0.1s                |
| 可扩展性 | 优秀 (K 的线性)        | 良好 (迭代)               |

其中  $d = 3$  (RBF 特征维度) 和  $K = 3$  (次优策略数量)。

## 8. 理论分析

### 8.1 可行域几何

LP-IRL 约束在权重空间中定义了一个**凸多面体**。每个次优策略贡献一个线性不等式约束：

$$w^\top (\mu_E - \mu_{\pi_i}) \geq 0$$

这些半空间与单纯形约束  $\sum w_i = 1, w_i \geq 0$  的交集定义了可行区域。

**关键洞察：**如果专家的特征期望位于次优特征期望的凸包内，可行区域可能为空或退化。这就是为什么需要多样化的次优策略（纯向上、纯向左、随机）来确保可行区域非空且有足够体积。

### 8.2 线性奖励近似

LP-IRL 和 MM-IRL 都在  $R(s) = \phi(s)^\top w$  的假设下恢复奖励权重。这是真实奖励的**线性函数逼近**。逼近质量取决于：

1. **特征表达能力：** $\Phi$  能否表示真实奖励？
2. **特征对齐：**专家的偏好是否与特征方向对齐？

对于我们的 RBF 特征，真实奖励  $R_{gt}(s)$  是稀疏的（目标处 +1，障碍物处 -1，其他位置 0）。RBF 特征可以近似这种结构：

- 特征 1（目标接近度） $\approx 1$  在目标处， $\approx 0$  在其他处  $\rightarrow$  良好匹配
- 特征 2（障碍距离） $\approx 0$  在障碍物处， $\approx 1$  在其他处  $\rightarrow$  良好匹配
- 特征 3（偏置） $\rightarrow$  捕获均匀偏移

### 8.3 局限性

**LP-IRL 局限性：**

- 不保证唯一解（可能存在多个最优权重）
- 对次优策略的选择敏感
- 不考虑轨迹熵

**MM-IRL 局限性：**

- 边距最大化可能过度强调“最容易”的次优策略
- SOCP 求解器可能比 LP 求解器慢
- L2 范数约束可能不是理想的正则化器

## 9. 挑战与解决方案

### 9.1 挑战：LP 退化解

**问题：**没有合适的目标函数时，LP 求解器可能返回退化解如  $w = [0, 0, 1]$  或  $w = [1, 0, 0]$ 。

**解决方案：**添加小的负权重和目标  $c = -0.01 \cdot \mathbf{1}$  以鼓励权重在特征间分配。

### 9.2 挑战：浮点误差导致的约束违反

**问题：**特征期望的数值计算可能对有效解产生小的约束违反。

**解决方案：**在约束中添加容差  $\delta = 5 \times 10^{-4}$ ，允许小的违反。

### 9.3 挑战：MM-IRL 边距不足

**问题：**如果边距  $m^*$  低于阈值 ( $10^{-4}$ )，解决方案可能无法有意义地将专家与次优策略分离。

**解决方案：**当边距不足时回退到均匀权重  $w = [1/d, \dots, 1/d]$ ，表明可用的次优策略没有提供足够的对比。

### 9.4 挑战：特征期望归一化

**问题：**不同长度轨迹的特征期望不能直接比较。

**解决方案：**应用  $(1 - \gamma)$  归一化，将累积特征和转换为折扣状态分布。这使得  $\mu$  独立于轨迹长度。

## 10. 结论

LP-IRL 和 MM-IRL 提供了优雅且理论上扎实的奖励恢复方法。本工作的关键贡献：

1. **LP-IRL：**通过线性规划有效求解特征匹配问题，通过小目标权重实现退化预防。Pearson 相关系数 0.502，策略成功率 100%。
2. **MM-IRL：**通过最大边距优化提供鲁棒的奖励恢复，策略成功率 100%。
3. **次优策略设计：**三个精心构造的次优策略（纯向上、纯向左、随机）提供多样化的对比约束。
4. **特征归一化：**折扣归一化的特征期望实现策略间的公平比较。

核心发现：

- LP-IRL 与真实奖励的 Pearson 相关系数为 0.502（中等）
- MM-IRL 的相关系数为 0.074（较低），但策略成功率同样为 100%
- 这直接验证了**奖励模糊性**现象：不同的奖励函数可以产生相同的最优策略

两种算法的结果为学生 4 的综合对比分析提供了基础，并为 MaxEnt-IRL 和 Preference-BT 方法（学生 3）提供了经典基线。

本报告引用的图表

| 图表编号 | 说明                           | 文件路径                                   |
|------|------------------------------|----------------------------------------|
| S2-1 | 特征期望：专家与次优策略对比               | figures/s2_feature_expectations.png    |
| S2-2 | LP-IRL 可行域（2D 投影）            | figures/s2_lp_constraints.png          |
| S2-3 | MM-IRL 边距分析与权重可视化            | figures/s2_mm_margin.png               |
| S2-4 | 次优策略状态访问热力图（3 种策略）           | figures/s2_suboptimal_trajectories.png |
| S2-5 | LP-IRL 与 MM-IRL 奖励场对比（3 奖励场） | figures/s2_reward_fields.png           |
| S2-6 | 奖励场差异分析（3 差异图）               | figures/s2_reward_differences.png      |