

Student 3 报告：最大熵 IRL 与基于偏好的学习

1. 引言

作为 IRL 项目团队的学生 3，我的职责聚焦于两种高级奖励恢复方法：**最大熵 IRL (MaxEnt-IRL)**，通过概率轨迹建模解决模糊性问题；以及**基于偏好的学习 (Bradley-Terry)**，从成对轨迹比较而非完整演示中恢复奖励。

1.1 职责概述

- **MaxEnt-IRL 实现**：Ziebart 等 (2008) 算法搭配软值迭代
- **Preference-BT 实现**：Bradley-Terry 模型搭配基于梯度的优化
- **收敛分析**：梯度范数、权重演化和损失曲线的详细跟踪
- **状态访问分析**：经验专家与 MaxEnt 诱导访问频率的对比
- **软策略与硬策略对比**：学习策略中熵的分析

2. 最大熵 IRL

2.1 动机：模糊性问题

经典 IRL 方法 (LP-IRL、MM-IRL) 受**奖励模糊性**困扰：许多奖励函数可以解释相同的专家行为。MaxEnt-IRL (Ziebart 等, 2008) 通过选择满足专家特征期望的**最大熵轨迹分布**来解决这个问题。这产生了与数据一致的最不偏committed的奖励分布。

最大熵原理：在所有满足特征匹配约束的分布中，选择熵最大的那个：

$$P^* = \arg \max_P H(P) \quad \text{s.t.} \quad \mathbb{E}_P[\phi(\tau)] = \mu_E$$

2.2 轨迹分布

MaxEnt-IRL 对轨迹 $\tau = (s_0, a_0, s_1, a_1, \dots, s_T)$ 的概率建模为：

$$P(\tau|\theta) = \frac{1}{Z(\theta)} \exp\left(\sum_{t=0}^T \gamma^t R(s_t)\right) \cdot P(s_0) \prod_{t=0}^{T-1} P(s_{t+1}|s_t, a_t)$$

其中：

- $R(s) = \phi(s)^\top \theta$ 是参数化奖励
- $Z(\theta) = \sum_{\tau} \exp(\text{reward}(\tau))$ 是配分函数
- 转移动力学 $P(s'|s, a)$ 已知

2.3 软值迭代

MaxEnt-IRL 的核心创新是**软 Bellman 回溯**，它将标准的 $\max$ 算子替换为 softmax ：

软 Q 函数：

$$Q_{soft}(s, a) = R(s) + \gamma \sum_{s'} P(s'|s, a) V_{soft}(s')$$

软 V 函数：

$$V_{soft}(s) = \text{softmax}_a Q_{soft}(s, a) = \log \sum_a \exp(Q_{soft}(s, a))$$

这产生了一个**随机策略**：

$$\pi(a|s) = \frac{\exp(Q_{soft}(s, a))}{\sum_{a'} \exp(Q_{soft}(s, a'))}$$

与硬值迭代的关键区别：

- 硬 VI: $V(s) = \max_a Q(s, a) \rightarrow$ 确定性策略
- 软 VI: $V(s) = \log \sum_a \exp(Q(s, a)) \rightarrow$ 具有熵的随机策略

2.4 梯度计算

关于 θ 的对数似然梯度为：

$$\nabla_{\theta} \mathcal{L} = \mu_E - \mathbb{E}_{P(\tau|\theta)}[\phi(\tau)] = \mu_E - \sum_s D(s) \phi(s)$$

其中 $D(s)$ 是当前软策略下的**折扣状态访问频率**：

$$D = D_0(I - \gamma P^{\pi})^{-1}$$

其中 $P_{ss'}^\pi = \sum_a \pi(a|s)P(s'|s, a)$ 是软策略诱导的转移矩阵。

2.5 算法步骤

初始化: $\theta = \theta$

For 迭代 = 1, ..., N:

1. 计算奖励: $R(s) = \phi(s)^\top \theta$
2. 软值迭代 $\rightarrow V_soft, Q_soft, \pi_soft$
3. 计算软策略转移: P^π
4. 求解状态访问: $D = D_0(I - \gamma P^\pi)^{-1}$
5. 计算梯度: $\nabla \theta = \mu_E - D \cdot \Phi$
6. 更新: $\theta \leftarrow \theta + \alpha \cdot \nabla \theta$ (带梯度裁剪和学习率衰减)

2.6 数值稳定性措施

MaxEnt-IRL 由于指数项容易出现数值不稳定。我们实现了多项保护措施:

1. Softmax 数值技巧:

$$\text{softmax}(x) = \frac{\exp(x - \max(x))}{\sum \exp(x - \max(x))}$$

这通过居中指数的方法防止溢出。

2. 梯度裁剪:

$$\nabla_\theta \leftarrow \text{clip}(\nabla_\theta, -0.05, 0.05)$$

这防止可能导致优化不稳定的大梯度步。

3. 学习率衰减:

$$\alpha_t = \frac{\alpha_0}{1 + 0.05 \cdot t}$$

这通过随迭代减少步长确保收敛。

2.7 收敛分析

图引用: 见图 `s3_maxent_convergence.png` 了解完整的收敛分析。

收敛指标：

指标	初始值	最终值	解释
梯度范数	较大	接近 0	趋近驻点
权重 w_0 （目标）	0.00	收敛值	学习目标导向奖励
权重 w_1 （障碍）	0.00	收敛值	学习障碍物规避
权重 w_2 （偏置）	0.00	收敛值	学习均匀偏移
目标奖励	0.00	收敛值	目标状态的奖励收敛

观察结果：

- 梯度范数单调递减，表明稳定收敛
- 权重 w_0 （目标接近度）增长最快，因为专家主要向目标移动
- 学习率衰减防止后期迭代中的振荡

2.8 状态访问频率

图引用：见图 s3_visitation_comparison.png 了解专家经验访问与 MaxEnt 诱导访问的对比。

分析：

- **专家经验**：通过对 500 条干净轨迹中的状态访问计数计算
- **MaxEnt 诱导**：通过分析计算 $D = D_0(I - \gamma P^\pi)^{-1}$ 得到
- **一致性**：良好的一致性表明 MaxEnt-IRL 恢复了产生与专家类似状态访问模式的奖励

最大熵原理确保诱导的访问分布与专家的匹配，同时在其他地方保持最大熵（最小额外假设）。

2.9 软值迭代与硬值迭代对比

图引用：见图 s3_soft_vs_hard_vi.png 了解价值函数和策略熵的对比。

性质	硬 VI	软 VI
Bellman 回溯	$\max_a Q(s, a)$	$\log \sum_a \exp(Q(s, a))$
策略	确定性 ($\arg \max$)	随机性 (softmax)
熵	0 (零熵)	>0 (正熵)
鲁棒性	对奖励噪声敏感	更鲁棒 (平滑)

性质	硬 VI	软 VI
探索	无（贪婪）	内置（softmax 探索）

策略熵图：软策略熵 $H(\pi(\cdot|s)) = -\sum_a \pi(a|s) \log \pi(a|s)$ 在状态空间中变化：

- **高熵：**在决策点附近（多个动作具有相似 Q 值）
- **低熵：**在目标或障碍物附近（最优动作明确）

3. 基于偏好的学习（Bradley-Terry）

3.1 动机：从偏好中学习

虽然 MaxEnt-IRL 从完整演示（状态-动作序列）中学习，但基于偏好的学习只需要**成对比较**："轨迹 τ_i 比轨迹 τ_j 更好"。这在许多设置中更自然：

- 人类发现比较两种行为比演示最优行为更容易
- 在机器人学习中，执行演示可能成本高昂，但评判预记录的轨迹很便宜
- 偏好数据可以从非专家用户收集

3.2 Bradley-Terry 模型

Bradley-Terry 模型（Bradley & Terry, 1952）定义轨迹 τ_i 优于 τ_j 的概率为：

$$P(\tau_i \succ \tau_j) = \sigma(R(\tau_i) - R(\tau_j)) = \frac{1}{1 + \exp(-(R(\tau_i) - R(\tau_j)))}$$

其中 $R(\tau) = \sum_{t=0}^T \gamma^t R(s_t)$ 是轨迹的累积折扣奖励。

3.3 长度归一化的轨迹特征

偏好学习中的一个关键问题是**轨迹长度偏差**：较长的轨迹自然累积更多奖励，这可能使学习产生偏差。我们通过按长度归一化轨迹特征来解决这个问题：

$$\tilde{\phi}(\tau) = \frac{1}{T} \sum_{t=0}^T \gamma^t \phi(s_t)$$

这确保奖励比较基于**每步平均质量**而非总累积奖励。

3.4 优化目标

给定 N 个偏好对 $\{(i_k, j_k), y_k\}_{k=1}^N$ ，其中 $y_k \in \{0, 1\}$ ，我们最大化对数似然：

$$\max_{\theta} \sum_{k=1}^N [y_k \log P(\tau_{i_k} \succ \tau_{j_k}) + (1 - y_k) \log P(\tau_{j_k} \succ \tau_{i_k})]$$

这等价于最小化**二元交叉熵损失**：

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{k=1}^N [y_k \log \sigma(\Delta_k) + (1 - y_k) \log(1 - \sigma(\Delta_k))]$$

其中 $\Delta_k = R(\tau_{i_k}) - R(\tau_{j_k})$ 。

3.5 梯度计算

对数似然关于 θ 的梯度为：

$$\nabla_{\theta} \mathcal{L} = \frac{1}{N} \sum_{k=1}^N (y_k - \sigma(\Delta_k)) \cdot (\tilde{\phi}(\tau_{i_k}) - \tilde{\phi}(\tau_{j_k}))$$

这直觉上是：预测误差 $(y_k - \sigma(\Delta_k))$ 乘以两个轨迹之间的特征差异。

3.6 优化算法

初始化： $\theta = |\phi(\text{目标})| + \text{小噪声}$ （目标导向初始化）

For 迭代 = 1, ..., N:

1. 计算轨迹奖励： $R_i = \phi(\tau_i)^T \theta$
2. 计算偏好概率： $p = \sigma(R_i - R_j)$
3. 计算梯度： $\nabla \theta = (1/N) \sum (y - p) \cdot (\phi(\tau_i) - \phi(\tau_j))$
4. 添加目标导向正则化： $\text{reg} = \lambda \cdot (\phi_{\text{目标}} / |\phi_{\text{目标}}| - \theta / |\theta|)$
5. 更新： $\theta \leftarrow \theta + \alpha \cdot (\nabla \theta + \text{reg}) / (1 + 0.01 \cdot t)$
6. 投影： $\theta \leftarrow \max(\theta, 0.01)$ （确保正权重）

3.7 目标导向正则化

我们实现中的一个关键创新是**目标导向正则化**：

$$\text{reg} = 0.1 \cdot \left(\frac{|\phi(s_{\text{goal}})|}{\|\phi(s_{\text{goal}})\|} - \frac{\theta}{\|\theta\|} \right)$$

这鼓励权重向量指向与目标状态特征向量相似的方向。直觉是奖励应在目标处最高，提供引导智能体的自然"梯度场"。

3.8 权重正性约束

我们在每次迭代强制执行 $w \geq 0.01$ 。这确保：

- 1. 奖励函数有清晰的指向目标的梯度（所有特征正向贡献）
- 2. 学习到的奖励可解释（没有"负重要性"特征）
- 3. 优化避免负权重抵消正权重的病态解

3.9 学习曲线分析

图引用： 见图 `s3_preference_learning.png` 了解完整的学习曲线分析。

关键指标：

指标	初始值	最终值	解释
预测准确率	~50%（随机）	由数据决定	高于 50% = 有学习信号
交叉熵损失	0.693（随机）	由优化决定	递减 = 更好的校准

观察结果：

- 如果最终准确率显著高于 50%，偏好数据包含可学习的信号
- 如果准确率在 50% 附近徘徊，偏好对基本上是随机的（没有判别信息）
- 交叉熵损失对于调优良好的优化器应单调递减

3.10 特征缩放

为防止 sigmoid 函数的数值问题（对大输入饱和），我们在内部缩放轨迹特征：

$$\phi_{scaled} = \frac{\phi}{\max(|\phi|) + 10^{-8}}$$

优化后，权重被重新缩回到原始特征空间：

$$w_{final} = \frac{w_{scaled}}{feat_scale}$$

4. 对比分析：MaxEnt-IRL 与 Preference-BT

4.1 奖励场对比

图引用：见图 s3_maxent_pref_rewards.png 了解并排的奖励热力图。

方面	MaxEnt-IRL	Preference-BT
数据来源	专家演示（状态-动作）	成对比较（轨迹对）
监督强度	强（完整轨迹）	弱（二元标签）
样本效率	高（500 条轨迹）	中等（300 对来自 1000 条轨迹）
奖励平滑度	平滑（软策略）	取决于轨迹覆盖
计算成本	高（每次迭代矩阵求逆）	低（简单梯度）

4.2 理论性质

性质	MaxEnt-IRL	Preference-BT
唯一性	唯一（最大熵）	可能有多个最优解
一致性	当 $N \rightarrow \infty$ 时一致	当 $N \rightarrow \infty$ 时一致
对噪声的鲁棒性	中等（梯度裁剪有帮助）	高（正则化有帮助）
可扩展性	$O(T \cdot S^3)$ 每次迭代	$O(T \cdot N^2 \cdot d)$ 每次迭代

4.3 实际考虑

MaxEnt-IRL 适用于：

- 有完整专家演示可用
- 转移模型已知
- 需要原则性的概率解

Preference-BT 适用于：

- 只有相对评判可用（例如来自人类）
- 转移模型未知
- 计算效率很重要

5. 挑战与解决方案

5.1 挑战：MaxEnt 数值溢出

问题：softmax 操作 $\exp(Q)$ 对于大 Q 值可能溢出。

解决方案：使用数值稳定的 softmax: $\text{softmax}(x) = \exp(x - \max(x)) / \sum \exp(x - \max(x))$ 。

5.2 挑战：矩阵求逆奇异

问题：计算 $D = D_0(I - \gamma P^\pi)^{-1}$ 在 $(I - \gamma P^\pi)$ 奇异时可能失败。

解决方案：当矩阵求逆失败时回退到 $D = D_0$ 。实际上，在 $\gamma < 1$ 和随机转移下，矩阵几乎总是可逆的。

5.3 挑战：偏好数据低区分度

问题：当偏好标签接近 50/50 分配时，数据没有可学习的信号。

解决方案：检测此条件（均值标签值在 48%-52% 之间）并回退到目标导向的默认权重。这避免在无信息数据上浪费计算。

5.4 挑战：偏好学习中的梯度爆炸

问题：轨迹对之间的大特征差异可能产生爆炸梯度。

解决方案：

1. 内部特征缩放（除以最大绝对特征值）
2. 正权重投影 ($w \geq 0.01$)
3. 学习率随迭代次数衰减

6. 结论

MaxEnt-IRL 和 Preference-BT 代表了两种根本不同的奖励恢复方法：

- 1. **MaxEnt-IRL**: 提供了原则性的概率框架，通过最大熵解决奖励模糊性。软值迭代产生平滑、鲁棒的奖励场，具有良好校准的状态访问频率。
- 2. **Preference-BT**: 提供了一种灵活的、样本高效的方法，从弱监督（成对比较）中学习。目标导向正则化和长度归一化确保稳定和可解释的奖励恢复。

两种方法都通过解决 IRL 问题的不同方面补充了经典的 LP/MM-IRL 方法（学生 2）：MaxEnt-IRL 通过熵最大化，Preference-BT 通过基于偏好的学习。它们的组合结果为学生 4 的对比实验提供了全面的评估。

本报告引用的图表

图表编号	说明	文件路径
S3-1	MaxEnt-IRL 收敛分析	figures/s3_maxent_convergence.png
S3-2	状态访问：专家与 MaxEnt	figures/s3_visitation_comparison.png
S3-3	Preference-BT 学习曲线	figures/s3_preference_learning.png
S3-4	软 VI 与硬 VI 对比	figures/s3_soft_vs_hard_vi.png
S3-5	MaxEnt 与 Preference 奖励场	figures/s3_maxent_pref_rewards.png