

Student 4 报告：策略训练、综合对比与完整分析

1. 引言

作为 IRL 项目团队的学生 4，我的职责是弥合奖励恢复与实际性能之间的差距：从恢复的奖励中训练策略、对所有四种 IRL 算法进行全面对比实验、执行噪声消融研究，并对项目的发现进行整体分析。

1.1 职责概述

- **策略训练**：使用所有 IRL 算法恢复的奖励函数进行值迭代
- **综合评估**：公平对比 LP-IRL、MM-IRL、MaxEnt-IRL 和 Preference-BT
- **噪声消融研究**：系统评估算法对演示噪声的鲁棒性
- **奖励相关性分析**：恢复奖励与真实奖励之间的 Pearson 和 Spearman 相关性
- **轨迹可视化**：学习策略行为的定性对比
- **复杂度分析**：运行时间和理论复杂度对比

2. 从恢复奖励中训练策略

2.1 使用恢复奖励的值迭代

在每种 IRL 算法恢复奖励权重向量 w 后，我们构造奖励函数：

$$R(s) = \phi(s)^\top w$$

并使用值迭代训练最优策略：

$$V(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) [R(s') + \gamma V(s')]$$

$$\pi(s) = \arg \max_a \sum_{s'} P(s'|s, a) [R(s') + \gamma V(s')]$$

算法在 $\max_s |V_{new}(s) - V_{old}(s)| < 10^{-9}$ 时收敛。

2.2 奖励缩放

IRL 中一个已知问题是恢复的奖励可能具有任意尺度。为确保有效的策略训练，我们对所有恢复的奖励应用统一的缩放因子 5.0：

$$R_{scaled}(s) = 5.0 \cdot R(s)$$

这种缩放不改变最优策略（因为值迭代对正奖励缩放具有不变性），但它改善了价值函数计算的数值条件。

2.3 策略评估协议

所有策略在**相同条件**下进行评估：

参数	值
起始位置	固定在 (0, 0)
试验次数	100
每次试验最大步数	150
环境随机性	10%
成功标准	智能体到达目标 (9, 9)

指标：

- **成功率**：到达目标的试验比例
- **平均步数**：到达目标的平均步数（仅成功试验）

2.4 基线策略

作为对比参考，我们对比了两个基线策略：

真实策略：在真实奖励 $R_{gt}(s)$ 上训练。这代表了理论上的性能上限。

随机策略：均匀随机动作选择。预期成功率约 25%（4 个动作中选 1 个）。

3. 综合算法对比

3.1 性能对比表

以下是所有策略在固定起点 (0,0) 评估 100 次的结果：

方法	成功率	平均步数	Pearson 相关	目标排名
Ground Truth	100.0%	21.0	1.000	1/100
Random	0.0%	—	—	—
LP-IRL	100.0%	20.8	0.502	1/100
MM-IRL	100.0%	20.8	0.074	1/100
MaxEnt-IRL	100.0%	20.6	0.368	1/100
Preference-BT	100.0%	20.6	0.293	1/100

指标解释：

- **成功率**：主要指标——策略到达目标的频率
- **平均步数**：效率——步数越少路径越直接
- **Pearson 相关系数**：恢复奖励与真实奖励场之间的线性相关性
- **Spearman 相关系数**：排名相关性——恢复奖励是否正确排名状态？
- **目标排名**：目标状态在恢复奖励排序列表中的位置（越低越好）

3.2 雷达图对比

图引用：见图 s4_radar_comparison.png 了解多指标雷达图。

雷达图将所有指标归一化到 [0, 1] 并绘制四个维度：

1. **成功率**：直接策略性能
2. **路径效率**：平均步数的倒数（步数越少越好）
3. **Pearson 相关性**：奖励场准确度（绝对值）
4. **Spearman 相关性**：奖励排名准确度（绝对值）

3.3 奖励场热力图

图引用：见 figures/fig_reward_heatmap.png 了解全面的奖励场对比。

定性分析：

- **真实奖励**：稀疏奖励（目标处 +1，障碍物处 -1，其他位置 0）
- **LP-IRL**：奖励场满足特征匹配约束；由于奖励模糊性，可能不完全匹配真实奖励
- **MM-IRL**：由于边距最大化产生更平滑的奖励场；倾向于更广泛地分布奖励
- **MaxEnt-IRL**：最平滑的奖励场；最大熵原理产生最少假设的分布
- **Preference-BT**：奖励场反映成对偏好结构；可能与真实奖励不同，但应产生正确的相对排序

3.4 策略轨迹可视化

图引用：见图 `s4_policy_trajectories.png` 了解所有五种策略的轨迹叠加。

观察结果：

- **真实策略**：干净、直接的路径通往目标，避开所有障碍物
- **LP-IRL**：如果奖励恢复准确则路径相似；如果奖励模糊可能显示绕行
- **MM-IRL**：由于更平滑的奖励场可能采取略微不同的路线
- **MaxEnt-IRL**：可能展现更多样化的路径（最大熵鼓励探索）
- **Preference-BT**：路径质量取决于偏好数据的覆盖范围

3.5 关键发现

所有四种 IRL 算法都实现了 100% 的成功率，与真实策略相当，且显著优于随机策略（0%）。这表明在我们的 10×10 GridWorld 环境中，所有算法都能有效地恢复足以引导智能体到达目标的奖励函数。

在平均步数方面：

- MaxEnt-IRL 和 Preference-BT 达到最短的平均路径（20.6 步）
- LP-IRL 和 MM-IRL 略多（20.8 步）
- 真实策略为 21.0 步

这有趣地表明，某些 IRL 算法恢复的奖励产生的策略甚至比真实奖励下的最优策略更高效。

4. 噪声消融研究

4.1 动机

IRL 中一个关键问题是：**这些算法对演示数据中的噪声有多鲁棒？** 现实世界的专家演示很少完美——它们可能包含次优动作、犹豫或错误。理解算法对噪声的鲁棒性对于实际部署至关重要。

4.2 实验设计

噪声水平：我们测试五个动作翻转噪声水平： $\eta \in \{0.0, 0.1, 0.2, 0.3, 0.4\}$

协议：

1. 对于每个噪声水平 η ，生成 500 条具有 η 动作翻转概率的轨迹
2. 从噪声轨迹计算特征期望 μ_{noisy}
3. 在所有四种 IRL 算法上运行噪声数据
4. 在固定起点 (0, 0) 评估所得策略的成功率
5. 计算恢复奖励与真实奖励之间的 Pearson 相关性

偏好噪声：对于 Preference-BT，我们在每个水平额外添加 5% 偏好标签噪声。

4.3 结果：策略成功率

噪声	LP-IRL	MM-IRL	MaxEnt-IRL	Preference-BT
0.0	99%	100%	100%	100%
0.1	0%	100%	100%	100%
0.2	0%	100%	100%	100%
0.3	0%	100%	100%	100%
0.4	1%	100%	100%	100%

图引用：见图 s4_ablation_detailed.png（左面板）了解噪声鲁棒性曲线。

4.4 结果分析

LP-IRL 的噪声敏感性：

- LP-IRL 在噪声水平为 0.1 时成功率从 99% 骤降到 0%
- 这是因为 LP-IRL 依赖于硬约束——噪声特征期望可以显著改变可行区域
- 当专家的特征期望被噪声污染时，LP 约束可能变得不可行或产生误导性的权重

MM-IRL、MaxEnt-IRL 和 Preference-BT 的鲁棒性：

- 这三种算法在所有噪声水平下都保持 100% 的成功率
- MM-IRL 的边距最大化提供了稳定性，将解推离约束边界
- MaxEnt-IRL 的概率框架和带裁剪的梯度优化提供了自然的噪声抵抗

- Preference-BT 的偏好标签聚合了整个轨迹的信息，平均掉了单个动作噪声

4.5 关键洞察

噪声鲁棒性排名揭示了**样本效率**与**鲁棒性**之间的权衡：

- 做出更强假设的方法（LP：硬约束）更高效但对噪声更敏感
- 做出更弱假设的方法（Preference-BT：成对比较）更鲁棒但需要更多数据

图引用：见图 `fig_ablation_all.png` 了解所有算法的消融曲线。

5. 奖励相关性分析

5.1 Pearson 与 Spearman 相关性

Pearson 相关系数测量线性相关性：

$$r = \frac{\text{Cov}(R_{\text{recovered}}, R_{\text{gt}})}{\sigma_{\text{recovered}} \cdot \sigma_{\text{gt}}}$$

Spearman 相关系数测量排名相关性：

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

其中 d_i 是状态 i 的排名差异。

5.2 相关性矩阵

图引用：见图 `s4_reward_correlation.png` 了解完整的 Pearson 和 Spearman 相关性矩阵。

5.3 奖励模糊性现象

IRL 研究中的一个根本发现是**低奖励相关性并不意味着差的策略性能**。这是因为：

1. **仿射不变性：** $R'(s) = \alpha R(s) + \beta$ 对于 $\alpha > 0$ 产生相同的最优策略
2. **整形不变性：** $R'(s) = R(s) + \gamma \Phi(s) - \Phi(s')$ （基于势能的整形）保持最优策略
3. **区域等价：**只要奖励正确识别目标为最高价值状态，其他状态的确切值就不那么重要

这解释了为什么 IRL 算法可以实现高策略成功率，同时与真实奖励奖励具有低 Pearson 相关性。

我们的实验数据中的具体体现：

- MM-IRL 的 Pearson 相关系数仅为 0.074，但策略成功率为 100%
- LP-IRL 的相关系数为 0.502，同样达到 100% 成功率
- MaxEnt-IRL 和 Preference-BT 的相关系数分别为 0.368 和 0.293，也都达到 100% 成功率

这强有力地验证了奖励模糊性现象：不同的奖励函数可以产生相同的最优策略。

6. 计算复杂度分析

6.1 理论复杂度

算法	时间复杂度	空间复杂度	关键操作
LP-IRL	$O(d^3 + K \cdot d^2)$	$O(d^2)$	LP 求解器 (HiGHS)
MM-IRL	$O(T \cdot (d + K)^3)$	$O((d + K)^2)$	SOCP 求解器 (SCS)
MaxEnt-IRL	$O(T \cdot (S^3 + S^2 \cdot A))$	$O(S^2 \cdot A)$	软 VI、矩阵求逆
Preference-BT	$O(T \cdot N \cdot d)$	$O(N \cdot d)$	梯度计算

其中：

- $d = 3$ ：特征维度
- $K = 3$ ：次优策略数量
- $S = 100$ ：状态数量
- $A = 4$ ：动作数量
- T ：迭代次数
- $N = 300$ ：偏好对数量

6.2 运行时间对比

算法	相对速度	说明
LP-IRL	最快	线性规划求解，通常 < 0.01s
MM-IRL	中等	SOCP 迭代求解，通常 < 0.1s

算法	相对速度	说明
MaxEnt-IRL	最慢	每次迭代需要矩阵求逆 $O(S^3)$
Preference-BT	快	简单梯度计算，线性于偏好对数量

图引用：见图 s4_complexity.png 了解柱状图和复杂度分析。

6.3 可扩展性讨论

LP-IRL 和 MM-IRL：在特征维度 d 上扩展良好，但需要预计算的次优特征期望。在高维空间（如图像）中，这些方法需要函数逼近。

MaxEnt-IRL： $O(S^3)$ 矩阵求逆是瓶颈。对于大状态空间，需要近似方法（采样、函数逼近）。

Preference-BT：最具可扩展性——复杂度与偏好对数量和特征维度成线性关系。适用于具有深度学习的高维设置。

7. 关键发现与洞察

7.1 结果总结

- 所有四种 IRL 算法都恢复了能产生非平凡策略的奖励，成功率（100%）显著高于随机（0%），并与真实奖励上限（100%）相当。
- 与真实奖励的相关性中等到低，验证了奖励模糊性现象——不同的奖励可以产生相同的策略。
- 噪声鲁棒性在算法间差异显著，Preference-BT、MM-IRL 和 MaxEnt-IRL 在所有噪声水平下保持 100% 成功率，而 LP-IRL 在 10% 噪声下骤降到 0%。
- 计算效率权衡：LP-IRL 最快但最不鲁棒；MaxEnt-IRL 最有原则性但最昂贵。

7.2 算法推荐

场景	推荐算法	理由
干净专家数据，需要快速结果	LP-IRL	快速、简单、有效
需要鲁棒的奖励恢复	MM-IRL	最大边距提供稳定性
需要概率保证	MaxEnt-IRL	最大熵解决模糊性
只有偏好数据可用	Preference-BT	专为成对比较设计

场景	推荐算法	理由
噪声演示	Preference-BT / MM-IRL / MaxEnt-IRL	对动作噪声最鲁棒
大状态空间	Preference-BT	最具可扩展性

7.3 与 RLHF 的联系

Preference-BT 方法直接连接到**基于人类反馈的强化学习（RLHF）**，其中：

- 1. 奖励模型从人类偏好标签中学习（正是我们的 Preference-BT）
- 2. 策略被训练以最大化学习到的奖励（正是我们的值迭代步骤）

我们的 GridWorld 实验作为理解 RLHF 根本挑战的受控测试平台，包括奖励模糊性、噪声鲁棒性和偏好数据效率。

8. 伦理考量

8.1 奖励推断与价值对齐

IRL 旨在从智能体的行为中推断其价值观（奖励函数）。这具有深远的伦理影响：

- 1. **演示中的偏差**：如果专家的行为包含偏差（例如，由于文化因素而避开某些区域，而非物理障碍），恢复的奖励将编码并延续这些偏差。
- 2. **奖励错误指定**：错误恢复的奖励可能导致优化错误目标的策略，在安全关键应用中可能造成危害。
- 3. **透明度**：奖励模糊性意味着我们并不总能确定恢复的奖励是否真正捕获了预期的价值观。

8.2 缓解策略

- 1. **多样化演示**：从多个专家收集演示以平均化个体偏差
- 2. **偏好验证**：使用基于偏好的学习来验证恢复的奖励是否与人类价值观一致
- 3. **不确定性量化**：报告奖励恢复的置信区间，而不仅仅是点估计
- 4. **人在回路中**：允许人类迭代优化恢复的奖励

9. 结论

本项目成功地在含障碍物的 10×10 GridWorld 导航任务上实现并对比了四种 IRL 算法——LP-IRL、MM-IRL、MaxEnt-IRL 和 Preference-BT。综合评估揭示了以下发现：

- 1. **所有算法都产生了功能性的策略**，100% 的成功率证明了从演示和偏好中恢复奖励的可行性。
- 2. **奖励与真实奖励的相关性较低到中等**（Pearson 系数 0.074 到 0.502），确认了奖励模糊性现象——不同的奖励可以产生相同的最优策略。
- 3. **噪声鲁棒性差异显著**：LP-IRL 对演示噪声最为敏感（10% 噪声下从 99% 降至 0%），而 MM-IRL、MaxEnt-IRL 和 Preference-BT 在所有测试噪声水平下保持 100% 成功率。
- 4. **计算权衡**：速度、鲁棒性和理论保证之间存在权衡，没有单一算法在所有维度上占主导地位。
- 5. **与 RLHF 的联系**凸显了 IRL 研究对现代 AI 对齐挑战的相关性。

本项目提供了从环境设计和数据生成到奖励恢复和策略训练的完整管道，为不同 IRL 方法的优势和局限性提供了宝贵的洞察。

本报告引用的图表

图表编号	说明	文件路径
S4-1	多指标雷达图	figures/s4_radar_comparison.png
S4-2	噪声消融研究（详细）	figures/s4_ablation_detailed.png
S4-3	奖励相关性矩阵	figures/s4_reward_correlation.png
S4-4	策略轨迹对比	figures/s4_policy_trajectories.png
S4-5	计算复杂度	figures/s4_complexity.png
S4-6	奖励场热力图（综合）	figures/fig_reward_heatmap.png
S4-7	成功率对比	figures/fig_success_comparison.png
S4-8	消融曲线（所有算法）	figures/fig_ablation_all.png